

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút): <https://youtu.be/KRfclkoMF54>
- Link slides (dạng .pdf đặt trên Github của nhóm):
https://github.com/LoylP/CS2205.CH203/blob/main/CS2205.CH203_SlideDeCuong.FinalReport.pdf
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Nguyễn Hoàng Phúc
- MSSV: 250101100



- Lớp: CS2205.CH203
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 0
- Số câu hỏi QT cá nhân: 3
- Link Github:
<https://github.com/LoylP/CS2205.CH203>
- Link YouTube:
<https://youtu.be/KRfclkoMF54>

TÊN ĐỀ TÀI (IN HOA)

**XÂY DỰNG HỆ THỐNG PHÁT HIỆN CHIẾN DỊCH PHISHING VÀ TIN GIẢ
TẠI VIỆT NAM SỬ DỤNG MÔ HÌNH NGÔN NGỮ LỚN ĐA TÁC TỬ KẾT HỢP
TRUY XUẤT TRI THỨC TĂNG CƯỜNG**

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

**A MULTI-AGENT LARGE LANGUAGE MODEL SYSTEM WITH
RETRIEVAL-AUGMENTED GENERATION FOR DETECTING PHISHING
CAMPAIGNS AND FAKE NEWS IN VIETNAM**

TÓM TẮT *(Tối đa 400 từ)*

Sự bùng nổ của mạng xã hội và các ứng dụng nhắn tin tại Việt Nam đã tạo điều kiện để các chiến dịch lừa đảo và tin giả ngày càng lan rộng và tinh vi hơn. Các hình thức phổ biến bao gồm tin tức mạo danh cơ quan nhà nước, đường liên kết phishing, chiêu trò lừa đảo tài chính và quảng cáo tuyển dụng gian lận, phần lớn đều khai thác yếu tố cảm xúc và sự thiếu hụt thông tin của người dùng. Đáng lo ngại hơn, sự xuất hiện của các công cụ sinh nội dung dựa trên trí tuệ nhân tạo (AI) đã làm cho nội dung độc hại trở nên khó phân biệt với thông tin hợp lệ, trong khi các hệ thống phát hiện hiện tại chủ yếu dựa trên đặc trưng tĩnh và thiếu khả năng lý luận theo ngữ cảnh.

Để giải quyết những hạn chế trên, đề tài được lựa chọn với mong muốn đề xuất giải pháp ứng dụng các mô hình ngôn ngữ lớn và Multi-Agent Systems, trong đó mỗi tác tử AI đảm nhận một tác vụ chuyên biệt bao gồm phân tích đầu vào, kiểm tra tính hợp lệ của thực thể (URL, số điện thoại, tên miền), tra cứu thông tin trực tuyến theo thời gian thực, truy xuất bằng chứng từ cơ sở tri thức nội bộ và đưa ra kết luận cuối cùng kèm giải thích nhằm hỗ trợ người dùng phát hiện và xác minh thông tin một cách chính xác, minh bạch và theo thời gian thực.

GIỚI THIỆU (Tối đa 1 trang A4)

1. Lý do chọn đề tài

Sự phổ biến của mạng xã hội và các ứng dụng nhắn tin tại Việt Nam đã tạo môi trường thuận lợi cho các chiến dịch lừa đảo trực tuyến ngày càng tinh vi, bao gồm tin giả mạo danh tổ chức, đường liên kết phishing và chiêu trò gian lận tài chính [1]. Trong bối cảnh đó, sự lợi dụng công nghệ sinh nội dung AI khiến các nội dung độc hại trở nên ngày càng khó phân biệt với thông tin hợp lệ [2][3].

Các công cụ phát hiện hiện tại vẫn còn hạn chế về khả năng lý luận theo ngữ cảnh, không tích hợp nguồn kiểm chứng bên ngoài theo thời gian thực [4][5]. Hơn nữa, ngôn ngữ tiếng Việt với đặc thù cú pháp và nguồn tài nguyên NLP còn hạn chế chưa được các hệ thống hiện tại hỗ trợ đầy đủ [6][7]. Xuất phát từ thực tiễn đó, đề tài được đề xuất nhằm xây dựng một hệ thống xác minh tự động, có khả năng lý luận đa bước và cung cấp phản hồi minh bạch, phù hợp với đặc thù môi trường thông tin tiếng Việt.

2. Định nghĩa bài toán

Bài toán được xác định như sau:

- Đầu vào (Input): Một tuyên bố cần xác minh (văn bản, liên kết, email, số điện thoại hoặc ảnh chụp màn hình chứa văn bản).
- Đầu ra (Output):
 - Nhận phân loại: thật hoặc lừa đảo/tin giả
 - Giải thích kết quả dựa trên bằng chứng thu thập từ các nguồn uy tín
 - Ánh xạ chiến thuật tấn công (TTP mapping) nếu nội dung được xác định là có hại
 - Khuyến nghị hành động dành cho người dùng

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là nội dung số lưu hành trên các nền tảng truyền thông và ứng dụng nhắn tin tại Việt Nam. Phạm vi nghiên cứu tập trung vào:

Ngôn ngữ: tiếng Việt

Loại nội dung: tin tức giả mạo, đường liên kết phishing, mạo danh tổ chức, chiêu dụ đầu tư tài chính, quảng cáo tuyển dụng gian lận

Nguồn dữ liệu: Kế thừa các bộ dữ liệu tin giả tiếng Việt đã được công bố kết hợp thu thập bổ sung từ các nền tảng mạng xã hội và các cổng tin tức trực tuyến uy tín trong nước.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

1. Xây dựng bộ dữ liệu tiếng Việt phục vụ phát hiện lừa đảo trực tuyến: Thu thập, gán nhãn và kiểm định một tập dữ liệu khoảng 10.000 mẫu nội dung (thật và lừa đảo), phủ rộng các dạng gian lận phổ biến như phishing, tin giả mạo danh tổ chức và chiêu trò tài chính. Bộ dữ liệu sẽ được chuẩn hóa và phân chia thành các tập huấn luyện, kiểm định và kiểm thử theo tỉ lệ chuẩn, đảm bảo có thể tái sử dụng cho cộng đồng nghiên cứu.
2. Nghiên cứu và phát triển mô hình phân loại dựa trên LLM được tinh chỉnh cho tiếng Việt: Thực hiện đánh giá zero-shot trên nhiều LLM mã nguồn mở (Gemma 3, LLaMA 3, Qwen 3), sau đó tiến hành tinh chỉnh có hiệu quả tham số để đạt độ chính xác phân loại tối thiểu 90% trên bộ kiểm thử, với chỉ số URC (Undecided Response Count) thấp hơn 10, đảm bảo đầu ra nhất quán và phù hợp triển khai thực tế.
3. Thiết kế và triển khai hệ thống xác minh đa tác nhân tích hợp RAG: Xây dựng và triển khai nguyên mẫu hệ thống trên nền web, trong đó các tác nhân AI chuyên biệt phối hợp xử lý đầu vào, tra cứu tính hợp lệ của thực thể, truy xuất bằng chứng từ nguồn nội bộ và bên ngoài, đồng thời cung cấp phán quyết có giải thích minh bạch nhằm hỗ trợ người dùng cuối nhận diện và ứng phó với nội dung lừa đảo.

NỘI DUNG VÀ PHƯƠNG PHÁP

Nội dung 1: Xây dựng bộ dữ liệu tiếng Việt

Thu thập dữ liệu từ hai nguồn: Bộ dữ liệu được tổng hợp từ hai hướng song song. Nguồn thứ nhất kế thừa các tập dữ liệu tin giả tiếng Việt đã được gán nhãn từ các công trình nghiên cứu trước đó [6][7], bao phủ các chủ đề xã hội, chính trị và thông tin sai lệch phổ biến trên mạng xã hội.

Nguồn thứ hai thu thập dữ liệu mới thông qua một pipeline tự động lấy bài viết từ các cổng báo chí uy tín tại Việt Nam như VnExpress, Dân Trí, Thanh Niên, VTV. Ngoài ra, các nội dung lừa đảo được lan truyền thực tế trên Facebook, Zalo, Telegram và cảnh báo từ cơ quan chức năng (Bộ TT&TT, Cục An toàn thông tin) cũng được thu

thập bổ sung, bao gồm các dạng: giả mạo cơ quan nhà nước, lừa đảo tuyển dụng, chiêu dụ đầu tư tài chính và giả danh ngân hàng.


Dữ liệu được làm sạch, loại trùng lặp, gán nhãn nhị phân và bổ sung bằng các kỹ thuật data augmentation nhằm đưa tổng số mẫu lên khoảng 10.000 mẫu.

Nội dung 2: Nghiên cứu và tinh chỉnh mô hình LLM

Đánh giá zero-shot (baseline): Các mô hình LLM mã nguồn mở (LLaMA 3, Qwen 3, Gemma 3) được đánh giá zero-shot trên toàn bộ bộ dữ liệu đã xây dựng. Mỗi mô hình nhận cùng một mẫu prompt chuẩn và được yêu cầu phân loại nội dung để chọn ra các mô hình phù hợp dựa trên Accuracy, F1-score và chỉ số URC (đo tỉ lệ phản hồi không hợp lệ). Các mô hình phù hợp sau đó được tinh chỉnh bằng LoRA/PEFT thông qua thư viện Unsloth [9], với chiến lược huấn luyện đa epoch, bộ tối ưu AdamW và hàm mất mát Cross-entropy. Mô hình đạt $URC < 10$ và hiệu năng phân loại tốt nhất sẽ được chọn tích hợp vào hệ thống.

Nội dung 3: Thiết kế và triển khai hệ thống xác minh đa tác nhân tích hợp RAG

Kiến trúc đa tác nhân (Multi-Agent): Hệ thống được triển khai trên nền tảng CrewAI, tổ chức theo pipeline tuần tự gồm sáu tác nhân chuyên biệt, mỗi tác nhân đảm nhận một giai đoạn độc lập trong quy trình xác minh [10][11]:



Hình 2: Sơ đồ tổng quan hệ thống multi-agent.

Tác nhân	Nhiệm vụ chính
Input Analyzer	Tóm tắt đầu vào, trích xuất thực thể (URL, email, số điện thoại)
Entity Checker	Kiểm tra độ an toàn URL (VirusTotal), xác minh email/SĐT (Abstract API)
Domain Analyst	Tra cứu WHOIS, phân tích IP và tên miền
Web Researcher	Tìm kiếm bằng chứng theo thời gian thực (Google Search API)
Database Researcher	Truy vấn cơ sở tri thức nội bộ bằng Hybrid Search (BM25 + Embedding)
Final Verifier	Tổng hợp, đưa ra phán quyết và ánh xạ TTP nếu phát hiện lừa đảo

Cơ sở dữ liệu nội bộ gồm ba bảng: tin tức đã xác minh, danh mục hành vi lừa đảo (TTP) và lịch sử tương tác. Hệ thống sẽ được triển khai dưới dạng API RESTful kết hợp giao diện web (Next.js) hỗ trợ nhập văn bản hoặc ảnh chụp màn hình.

KẾT QUẢ MONG ĐỢI

Bộ dữ liệu: Một tập dữ liệu tiếng Việt gán nhãn khoảng 10.000 mẫu (nội dung thật và lừa đảo), được chuẩn hóa theo quy trình kiểm định thủ công và tự động, sẵn sàng phục vụ các nghiên cứu tiếp theo về phát hiện thông tin sai lệch trong môi trường tiếng Việt.

Mô hình phân loại: Ít nhất một mô hình LLM được tinh chỉnh đạt các chỉ số sau trên bộ kiểm thử:

- Accuracy, F1-score $\geq 90\%$
- URC = 0 (không có phản hồi không hợp lệ hoặc mơ hồ)

Hệ thống nguyên mẫu: Một ứng dụng web cho phép:

- Người dùng nhập nội dung văn bản hoặc ảnh chụp màn hình để xác minh
- Hệ thống trả về nhãn phân loại (*thật / lừa đảo*), lý giải dựa trên bằng chứng thu thập được, và khuyến nghị hành động cụ thể
- Khi phát hiện nội dung đáng ngờ, hệ thống ánh xạ sang các chiến thuật lừa đảo đã biết (TTP mapping)
- Quản trị viên theo dõi lịch sử xác minh và phân tích xu hướng qua bảng điều khiển riêng

Báo cáo kỹ thuật: Tài liệu mô tả đầy đủ kiến trúc hệ thống, quy trình xây dựng dữ liệu, kết quả thực nghiệm so sánh các mô hình, phân tích lỗi và định hướng phát triển trong tương lai.

TÀI LIỆU THAM KHẢO (*Định dạng DBLP*)

- [1] Abdilllah, R., Shukur, Z., Mohd, M., Murah, T.M.Z.: Phishing classification techniques: A systematic literature review. IEEE Access 10, 41574–41591 (2022)
- [2] Afane, K., Wei, W., Mao, Y., Farooq, J., Chen, J.: Next-generation phishing: How LLM agents empower cyber attackers. In: 2024 IEEE International Conference on Big Data (BigData), pp. 2558–2567. IEEE (2024)
- [3] Papageorgiou, E., Chronis, C., Varlamis, I., Himeur, Y.: A survey on the use of

large language models (LLMs) in fake news. *Future Internet* 16(8), 298 (2024)

[4] Alam, F., Cresci, S., Chakraborty, T., Silvestri, F., Dimitrov, D., Martino, G.D.S., Shaar, S., Firooz, H., Nakov, P.: A survey on multimodal disinformation detection. *CoRR* abs/2103.12541 (2021)

[5] Zhang, M., Lee, D., Zhao, Y.: Analysis of disinformation and fake news detection using fine-tuned large language model. *CoRR* abs/2309.04704 (2023)

[6] Huynh, A.T., Tran, P.: Utilizing transformer models to detect Vietnamese fake news on social media platforms. *KSII Transactions on Internet and Information Systems* 19(2), 1234–1249 (2025)

[7] Vinh, V.D., Do, P.: Detecting Vietnamese fake news. *Can Tho University Journal of Science* 58(1), 55–64 (2022)

[8] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474 (2020)

[9] Welbl, J., Stenning, S.: Fine-tuned 'small' LLMs (still) significantly outperform zero-shot generative AI models in text classification. *CoRR* abs/2402.01325 (2024)

[10] Wang, Q., Tsai, W.T., Shi, T., Liu, Z., Du, B.: Catch me if you can: A multi-agent synthetic fraud detection framework for complex networks. In: *2025 IEEE 41st International Conference on Data Engineering (ICDE)*, pp. 3629–3641. IEEE Computer Society (2025)

[11] Xiong, C., Zheng, G., Ma, X., Li, C., Zeng, J.: DelphiAgent: A trustworthy multi-agent verification framework for automated fact verification. *Information Processing & Management* 62(6), 104241 (2025)

