

XÂY DỰNG HỆ THỐNG PHÁT HIỆN CHIẾN DỊCH PHISHING VÀ TIN GIẢ TẠI VIỆT NAM SỬ DỤNG MÔ HÌNH NGÔN NGỮ LỚN ĐA TÁC TỬ KẾT HỢP TRUY XUẤT TRI THỨC TĂNG CƯỜNG



Nguyễn Hoàng Phúc - 25010100 | GV: PGS.TS Lê Đình Duy
Trường Đại học Công nghệ Thông tin,
Đại học Quốc gia Thành phố Hồ Chí Minh (ĐHQG - HCM)
CS2205 - Phương pháp nghiên cứu khoa học



What & Why

Sự bùng nổ của mạng xã hội tại Việt Nam tạo điều kiện cho các chiến dịch phishing và tin giả ngày càng tinh vi, trong khi các công cụ sinh nội dung AI khiến nội dung độc hại khó phân biệt với thông tin hợp lệ và các hệ thống phát hiện hiện tại thiếu khả năng lý luận theo ngữ cảnh. Đề tài đề xuất hệ thống xác minh tự động dựa trên Mô hình Ngôn ngữ Lớn và kiến trúc Multi-Agent, trong đó mỗi tác tử AI đảm nhận một tác vụ chuyên biệt bao gồm phân tích đầu vào, kiểm tra thực thể (URL, số điện thoại, tên miền), tra cứu thời gian thực và truy xuất bằng chứng nhằm hỗ trợ người dùng phát hiện và xác minh thông tin một cách chính xác, minh bạch.

Overview

Hệ thống xây dựng một pipeline xác minh thông tin đầu cuối, nhận đầu vào là văn bản, liên kết, email hoặc ảnh chụp màn hình nghi ngờ và trả về phán quyết có giải thích dựa trên bằng chứng.

Kiến trúc gồm ba tầng phối hợp:

Tầng	Thành phần	Vai trò
Dữ liệu	Dataset ~10.000 mẫu tiếng Việt	Huấn luyện & đánh giá mô hình
Mô hình	LLM tinh chỉnh (LoRA/PEFT)	Phân loại thật / lừa đảo
Hệ thống	Multi-Agent + RAG (CrewAI)	Xác minh đa bước, truy xuất bằng chứng

Problem Statement

Đầu vào (Input): Văn bản, liên kết, email, số điện thoại hoặc ảnh chụp màn hình chứa nội dung cần xác minh.

Đầu ra (Output):

- Nhãn phân loại: thật hoặc lừa đảo/tin giả
- Giải thích dựa trên bằng chứng từ nguồn uy tín
- TTP mapping: ánh xạ chiến thuật tấn công
- Khuyến nghị hành động cụ thể cho người dùng

Phạm vi: Nội dung tiếng Việt lưu hành trên mạng xã hội và tin nhắn; bao gồm tin giả mạo danh, phishing, chiêu trò lừa đảo tuyển dụng, đầu tư.

Expected Results

Kết quả thực nghiệm đạt:

- Accuracy & F1-score $\geq 90\%$ trên tập kiểm thử
- URC < 10 và độ trễ phản hồi (Latency) < 5 giây


Khả năng của hệ thống:

- Giao diện trực quan, thân thiện, người dùng dễ thao tác nhập tin tức cần xác minh và nhận kết quả ngay lập tức.
- Xác minh theo thời gian thực với độ trễ thấp, phù hợp triển khai thực tế.
- Tri thức được cập nhật liên tục không cần huấn luyện lại mô hình.
- Dashboard quản trị theo dõi lịch sử xác minh và phân tích xu hướng lừa đảo realtime.

Description

Kiến trúc hệ thống đa tác tử:

- Input Analyzer:** Tiếp nhận dữ liệu đầu vào từ người dùng.
- Entity Checker:** Kiểm tra độ tin cậy của các thực thể.
- Domain Analyst:** Phân tích tên miền và địa chỉ IP.
- Web Researcher:** Thu thập thông tin thời gian thực.
- Database Researcher:** Truy vấn cơ sở dữ liệu nội bộ.
- Final Verifier:** Tổng hợp kết quả, đưa ra kết luận và giải thích.



Hình 1: Sơ đồ tổng quan hệ thống multi-agent.

Future Work

- Mở rộng đầu vào đa phương thức
- Hỗ trợ các ngôn ngữ khác
- Triển khai cảnh báo chủ động qua các nền tảng mạng xã hội
- Tối ưu tốc độ phản hồi cho thiết bị di động
- Kết nối với hệ thống cảnh báo của Bộ TT&TT và Cục An toàn thông tin