

XÂY DỰNG HỆ THỐNG PHÁT HIỆN CHIẾN DỊCH PHISHING VÀ TIN GIẢ TẠI VIỆT NAM SỬ DỤNG MÔ HÌNH NGÔN NGỮ LỚN ĐA TÁC TỬ KẾT HỢP TRUY XUẤT TRI THỨC TĂNG CƯỜNG

Môn học: CS2205 - PHƯƠNG PHÁP LUẬN NCKH

Lớp: CS2205.CH203

GV: PGS.TS. Lê Đình Duy

HV: Nguyễn Hoàng Phúc - 250101100

Trường ĐH Công Nghệ Thông Tin, ĐHQG-HCM



Tóm tắt

- Lớp: CS2205.CH203
- Link Github của nhóm:
<https://github.com/LoylP/CS2205.JAN2026>
- Link YouTube video:
<https://youtu.be/KRfclkoMF54>
- Họ và tên: Nguyễn Hoàng Phúc - 250101100



Giới thiệu

Lý Do Chọn Đề Tài

Mạng xã hội & ứng dụng nhắn tin tại Việt Nam tạo môi trường thuận lợi cho lừa đảo & tin giả ngày càng tinh vi

Công cụ sinh nội dung AI làm nội dung độc hại khó phân biệt với thông tin hợp lệ

Hệ thống phát hiện hiện tại thiếu khả năng lý luận theo ngữ cảnh và không tích hợp nguồn kiểm chứng thời gian thực

Tiếng Việt với đặc thù cú pháp chưa được hỗ trợ đầy đủ trong các hệ thống NLP hiện tại

Định Nghĩa Bài Toán

Đầu Vào (Input)

Văn bản, liên kết, email, số điện thoại hoặc ảnh chụp màn hình chứa nội dung cần xác minh.

Đầu Ra (Output)

- Nhãn phân loại: thật hoặc lừa đảo/tin giả
- Giải thích dựa trên bằng chứng từ nguồn uy tín
- TTP mapping: ánh xạ chiến thuật tấn công
- Khuyến nghị hành động cụ thể cho người dùng

Mục tiêu

01

Xây dựng Bộ Dữ Liệu Tiếng Việt

Thu thập, gán nhãn và kiểm định ~10.000 mẫu nội dung (thật và lừa đảo), phủ rộng các dạng phishing, tin giả mạo danh tổ chức, chiêu trò tài chính. Chuẩn hóa theo tỉ lệ train/val/test chuẩn, sẵn sàng chia sẻ cho cộng đồng nghiên cứu.

02

Phát triển Mô hình Phân loại LLM

Đánh giá zero-shot nhiều LLM mã nguồn mở (Gemma 3, LLaMA 3, Qwen 3) và tinh chỉnh bằng LoRA/PEFT thông qua Unsloth, đạt Accuracy & F1-score $\geq 90\%$ và URC < 10 trên bộ kiểm thử.

03

Thiết kế & Triển khai Hệ thống Xác minh Đa Tác nhân RAG

Xây dựng nguyên mẫu web tích hợp Multi-Agent (CrewAI), RAG (BM25 + vector embedding), cung cấp phán quyết có giải thích minh bạch, TTP mapping và dashboard quản trị.

Nội dung và Phương pháp (1/3)

Nguồn 1 - Kế Thừa

Bộ dữ liệu tin giả tiếng Việt đã gán nhãn từ các nghiên cứu trước (Huynh & Tran 2025; Vinh & Do 2022)

Phủ các chủ đề: xã hội, chính trị, thông tin sai lệch phổ biến trên mạng xã hội

Nguồn 2 - Thu Thập Mới

Pipeline tự động từ báo chí uy tín: VnExpress, Dân Trí, Thanh Niên, VTV

Nội dung lừa đảo thực tế lan truyền trên Facebook, Zalo, Telegram

Cảnh báo từ Bộ TT&TT & Cục An toàn thông tin: mạo danh cơ quan, tuyển dụng giả, đầu tư tài chính

Xử lý: Làm sạch → Loại trùng lặp → Gán nhãn nhị phân → Data Augmentation → **~10.000 mẫu**

Nội dung và Phương pháp (2/3)

Giai đoạn 1: Zero-shot Baseline

Mô hình đánh giá:

- LLaMA 3
- Qwen 3
- Gemma 3

Metrics đánh giá:

- Accuracy & F1-score
- URC (Undecided Response Count)
- Tính nhất quán của đầu ra
- Latency

Giai đoạn 2: Fine-tuning với LoRA/PEFT

- Thư viện Unsloth — tối ưu trên GPU hạn chế
- Huấn luyện đa epoch với AdamW optimizer
- Hàm mất mát Cross-entropy
- Chọn mô hình đạt $URC = 0$ và hiệu năng tốt nhất để tích hợp hệ thống

Mục tiêu đầu ra:

Accuracy & F1-score $\geq 90\%$ | URC < 10

Nội dung và Phương pháp (3/3)

Kiến trúc hệ thống đa tác tử

Input Analyzer: Tiếp nhận dữ liệu đầu vào từ người dùng.


Entity Checker: Kiểm tra độ tin cậy của các thực thể.

Domain Analyst: Phân tích tên miền và địa chỉ IP.

Web Researcher: Thu thập thông tin thời gian thực.

Database Researcher: Truy vấn cơ sở dữ liệu nội bộ.

Final Verifier: Tổng hợp kết quả từ các tác nhân, đưa ra kết luận về độ tin cậy và giải thích.



Hình 1: Sơ đồ tổng quan hệ thống multi-agent.

-> Kiến trúc đề xuất giúp chuyên môn hóa từng tác vụ, cải thiện hiệu suất và độ minh bạch. Đồng thời có khả năng giải thích và thích ứng với sự thay đổi của tin giả, dễ dàng mở rộng để thêm các tác nhân hoặc công cụ mới.

Kết quả dự kiến

Bộ Dữ Liệu

- ~10.000 mẫu tiếng Việt gán nhãn
- Kiểm định thủ công + tự động
- Mở cho cộng đồng nghiên cứu

Model	Accuracy	F1-Score	URC	Latency(s)
Llama3	0.6	0.6	100	5
Qwen3	0.7	0.7	70	3
Gemma3	0.7	0.7	60	3
Llama3 (Finetuned)	0.8	0.8	20	5
Qwen3 (Finetuned)	0.9	0.9	10	3
Gemma3 (Finetuned)	0.9	0.9	5	3

User Input:

Tôi nhận được thông báo trúng thưởng Iphone16 và cần nhấp vào link sau để nhận thưởng <http://hk1107.com>.
Hãy xác nhận xem giúp tôi có đáng tin không.

English: I received a message claiming I won an iPhone 16 and was instructed to click the following link to claim the prize: <http://hk1107.com>. Please confirm for me if it is trustworthy.

Submitted

Bot Response:

Kết luận: ❌ Lừa đảo

Giải thích: URL "<http://hk1107.com/>" được đánh giá là "Nguy hiểm" với 6 báo cáo độc hại và 29 báo cáo không được phát hiện.

- Không có thông tin về IP, ngày tạo, nhà đăng ký, hoặc tổ chức liên quan đến domain này, điều này thường là dấu hiệu của một trang web không đáng tin cậy.

- Không có thông tin từ các nguồn đáng tin cậy xác nhận về chương trình trúng thưởng iPhone 16 từ nguồn này.

Gợi ý hành động: Không nhấp vào liên kết hoặc cung cấp bất kỳ thông tin cá nhân nào.

English:

Conclusion: ❌ Scam

Reasoning: The URL "<http://hk1107.com/>" is flagged as "Malicious" with 6 harmful reports and 29 undetected reports.

- There is no available information about the IP address, creation date, registrar, or associated organization, indicating that this domain is likely untrustworthy.

- No credible sources confirm the existence of an iPhone 16 prize campaign associated with this link.

Recommended Actions: Do not click the link or provide any personal information.

Hình 2: Ảnh minh họa hệ thống kiểm chứng thông tin

Tài liệu tham khảo

- [1] Abdilllah, R., Shukur, Z., Mohd, M., Murah, T.M.Z.: Phishing classification techniques: A systematic literature review. *IEEE Access* 10, 41574–41591 (2022)
- [2] Afane, K., Wei, W., Mao, Y., Farooq, J., Chen, J.: Next-generation phishing: How LLM agents empower cyber attackers. In: 2024 IEEE International Conference on Big Data (BigData), pp. 2558–2567. IEEE (2024)
- [3] Papageorgiou, E., Chronis, C., Varlamis, I., Himeur, Y.: A survey on the use of large language models (LLMs) in fake news. *Future Internet* 16(8), 298 (2024)
- [4] Alam, F., Cresci, S., Chakraborty, T., Silvestri, F., Dimitrov, D., Martino, G.D.S., Shaar, S., Firooz, H., Nakov, P.: A survey on multimodal disinformation detection. *CoRR abs/2103.12541* (2021)
- [5] Zhang, M., Lee, D., Zhao, Y.: Analysis of disinformation and fake news detection using fine-tuned large language model. *CoRR abs/2309.04704* (2023)
- [6] Huynh, A.T., Tran, P.: Utilizing transformer models to detect Vietnamese fake news on social media platforms. *KSII Transactions on Internet and Information Systems* 19(2), 1234–1249 (2025)
- [7] Vinh, V.D., Do, P.: Detecting Vietnamese fake news. *Can Tho University Journal of Science* 58(1), 55–64 (2022)
- [8] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474 (2020)
- [9] Welbl, J., Stenning, S.: Fine-tuned 'small' LLMs (still) significantly outperform zero-shot generative AI models in text classification. *CoRR abs/2402.01325* (2024)
- [10] Wang, Q., Tsai, W.T., Shi, T., Liu, Z., Du, B.: Catch me if you can: A multi-agent synthetic fraud detection framework for complex networks. In: 2025 IEEE 41st International Conference on Data Engineering (ICDE), pp. 3629–3641. IEEE Computer Society (2025)
- [11] Xiong, C., Zheng, G., Ma, X., Li, C., Zeng, J.: DelphiAgent: A trustworthy multi-agent verification framework for automated fact verification. *Information Processing & Management* 62(6), 104241 (2025)